

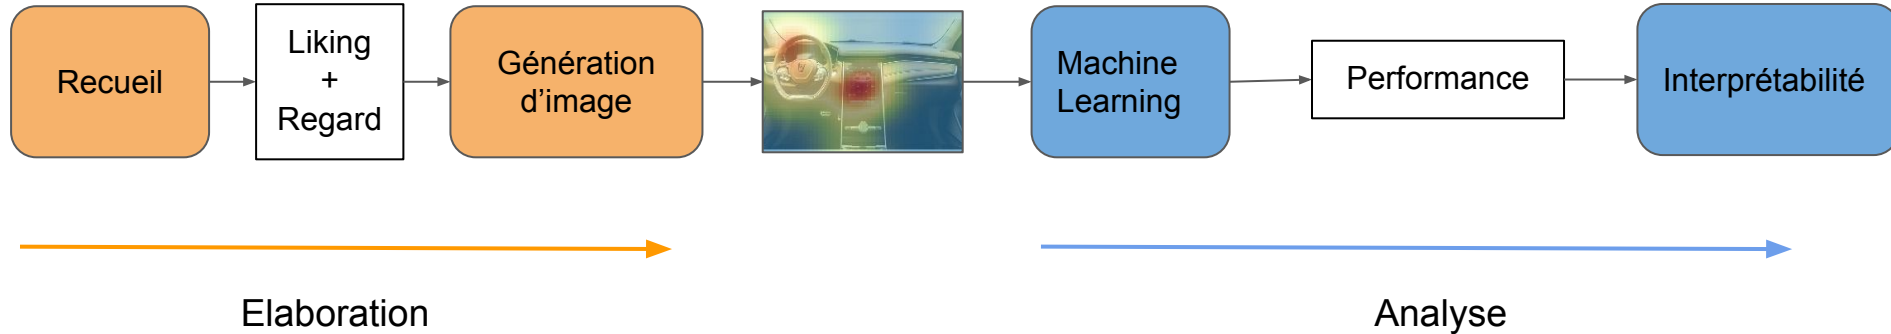





Eye-tracking à domicile, le machine learning au service des sciences cognitives




4 axes d'attaques pour concentrer les réflexions.





1 - Recueil des données





1.1 L'outil

Gaze recorder :

- reconnaissance du visage
- position des yeux
- trouver le regard

Points positifs	Points négatifs
Gratuit	Qualité
Sortie txt	Durée
Facile a prendre en main	Contraignant (immobilité)
Téléchargement simple	Peu de biblio






1.2 Les stimuli

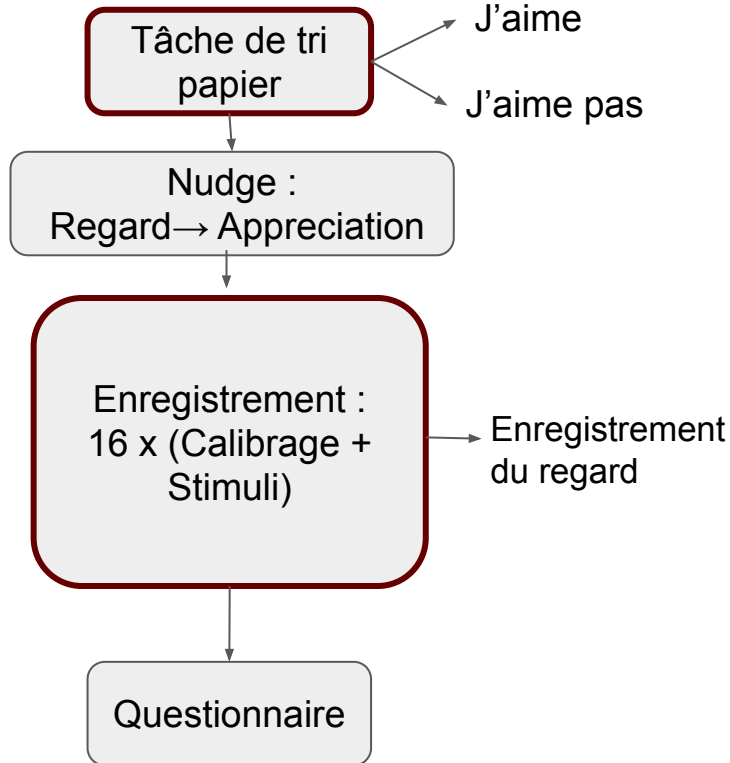
16 cockpits : interfaces homme-machine complexe




Critère de choix des Stimuli : design épuré, intégration de l'écran, ergonomie → Maximisation de la variabilité




1.3 Protocole



Résultat : 34 consommateurs x 16 stimuli
→ 544 individus statistiques



1.4 Vérification des données




Calibration : emplacement enregistrés de coordonnées réels


- Outil de **discrimination de la qualité** →
- Travail “manuel” → manque automatisé

Tri : J’aime / J’aime pas → classes d’apprentissage


- Manque : Changement d’avis - 2e tri final



- 57 parfaites
 - 139 proches
- 196**




- 114 exploitables
 - 94 compliquées
- 208**




- 140 impossibles
- 140**

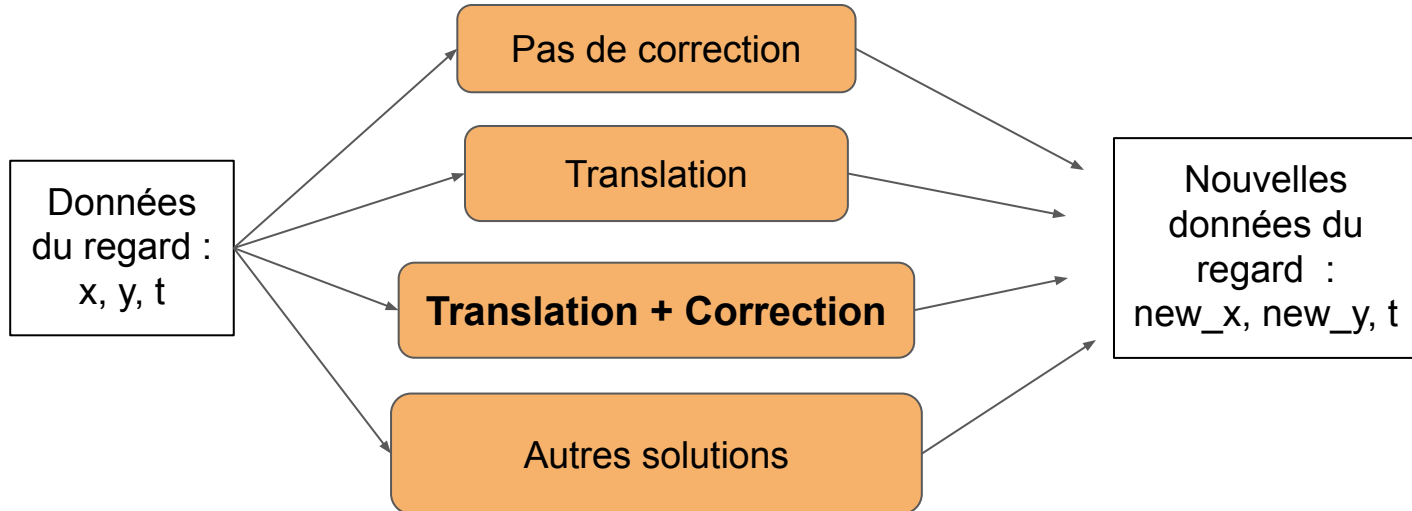
Total : 544




2 - Génération d'images : Inputs de notre classifieur



2.1 Correction des données






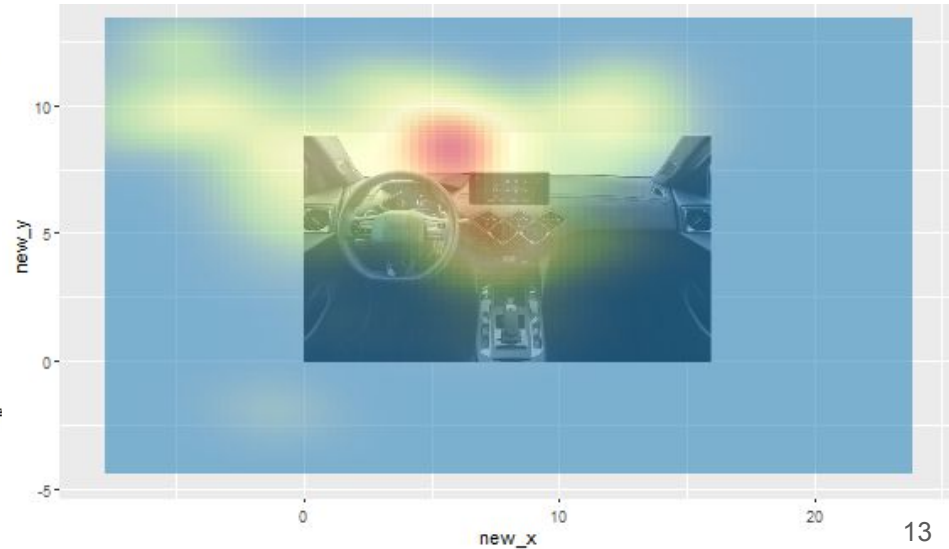
2.1 Correction des données


Données brutes

données calibrage



données stimuli






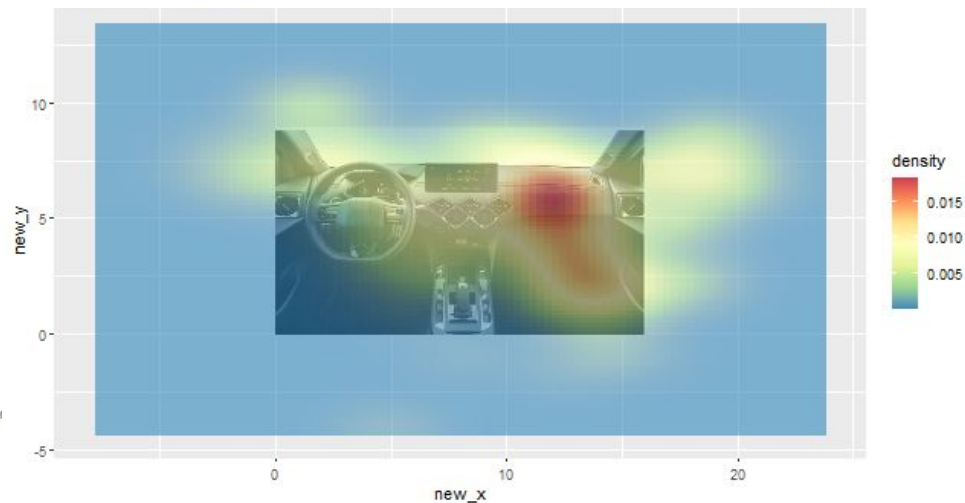
2.1 Correction des données


Données Translatées

données calibrage



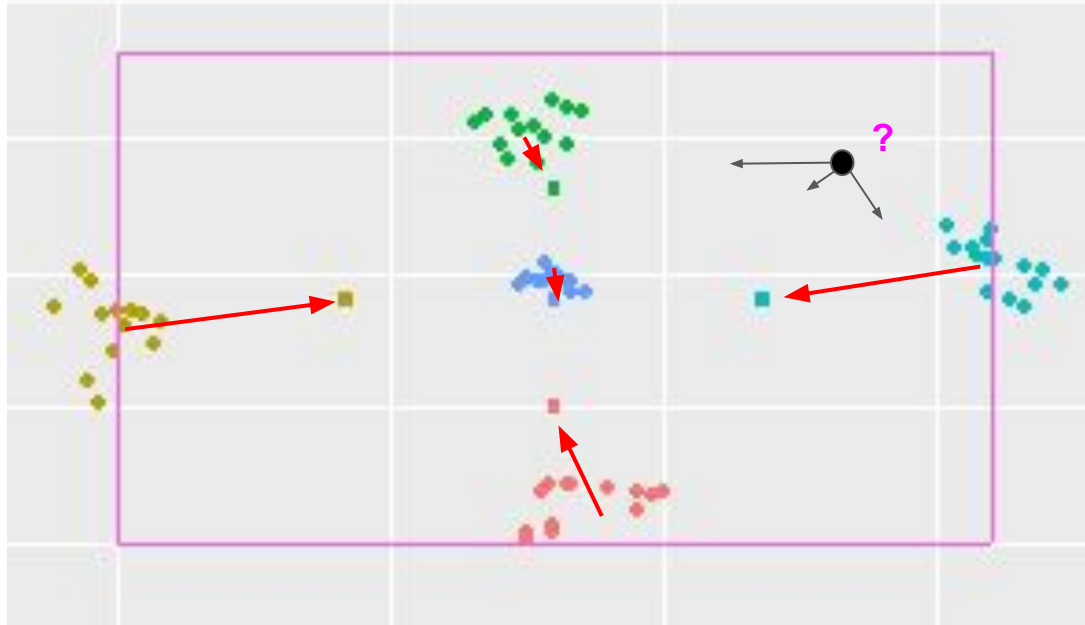
données stimuli






2.1 Correction des données

Combinaison linéaire pondérée grâce aux vecteurs “*cluster* → *barycentre*”







2.1 Correction des données


Données corrigées

données calibration

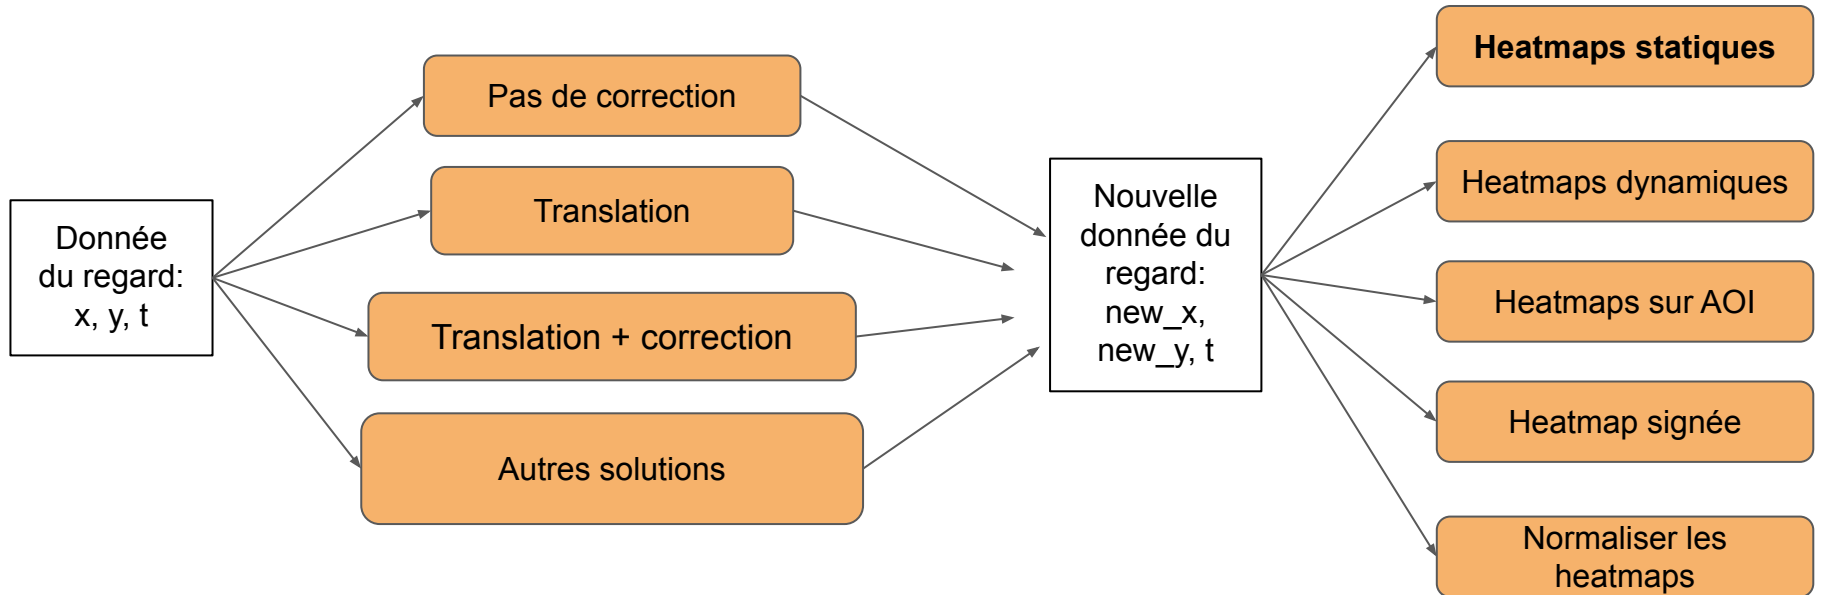



données stimuli





2.2 Présentation des données







2.2 Présentation des données

Chaque type de heatmap traduit une façon de coder l'information

Heatmaps statiques



Heatmaps dynamiques




Heatmaps sur AOI




Heatmaps signées

Normaliser les
heatmaps




3 - Machine learning



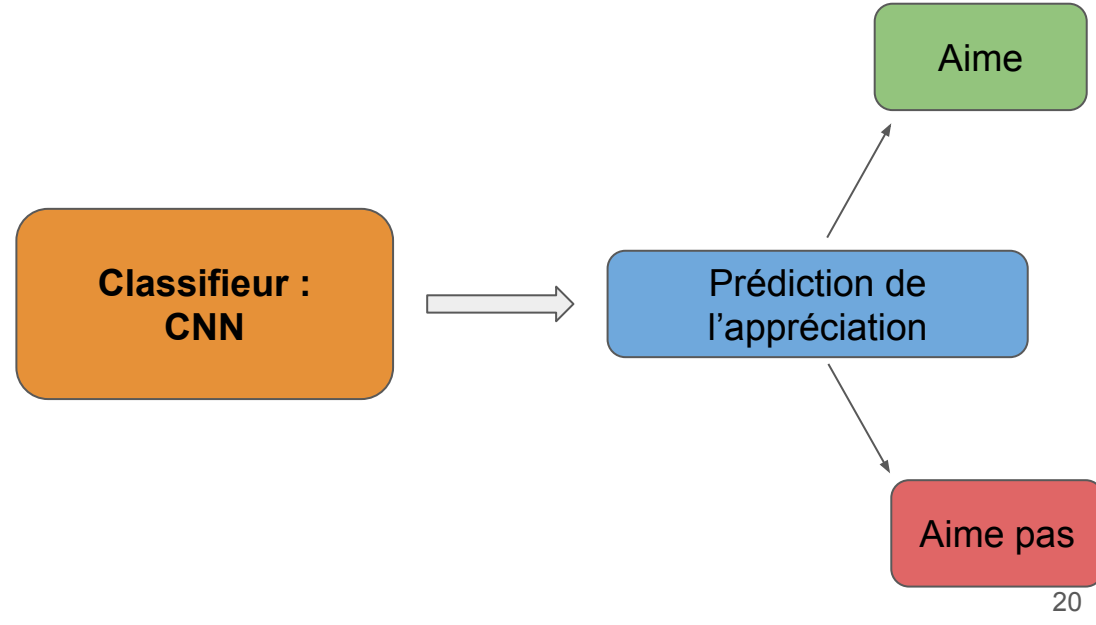
3.1 Le modèle : CNN


Heatmaps : variables explicatives



Appréciation : variable réponse

Images étiquetées :
aime/aime pas







3.2 Performances du modèle

Tableau comparatif des performances de notre classifieur selon le type de données

	Nombre d'image	Précision de classification
Heatmaps correctes corrigées	196	0.5
Heatmaps correctes non corrigés	196	0.5
Heatmaps parfaites non corrigées	57	0.5
Heatmaps simulées	100	0.99




4 - Interprétabilité



4.1 Algorithme

LIME (Local Interpretable Model-agnostic Explanations)

1 : Heatmaps




2 : découpage
en "superpixels"



3 : bootstrap en
noircissant certains
superpixels

4 : Prédiction de
l'appréciation


5 : zones
déterminantes






4.2 Résultats

Label 1




Label: 1
Probability: 1
Explanation Fit: 0.12




Zones
déterminantes

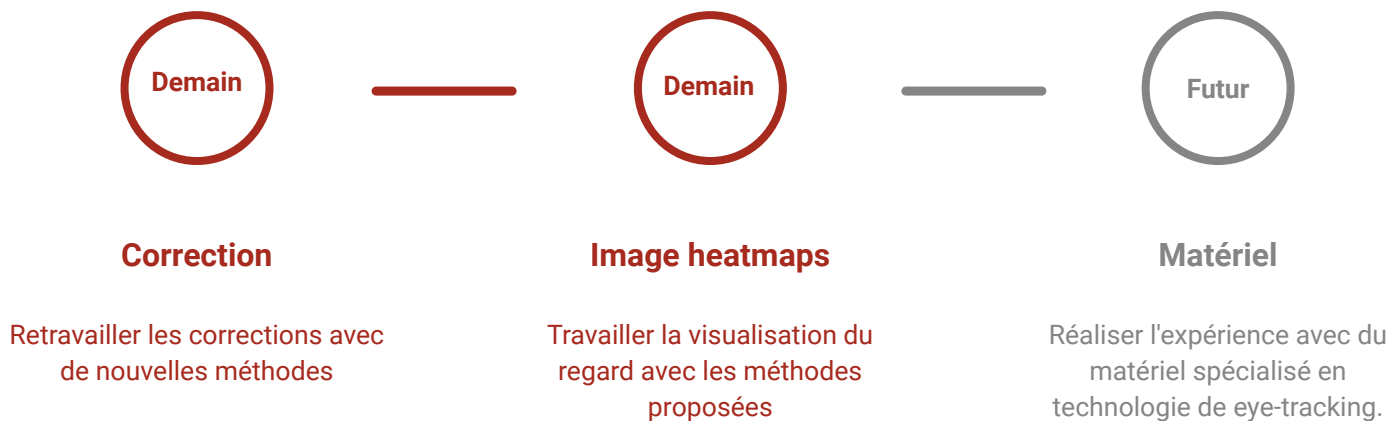
Label 2



Label: 2
Probability: 1
Explanation Fit: 0.22



Prochaines étapes :





Bilan :

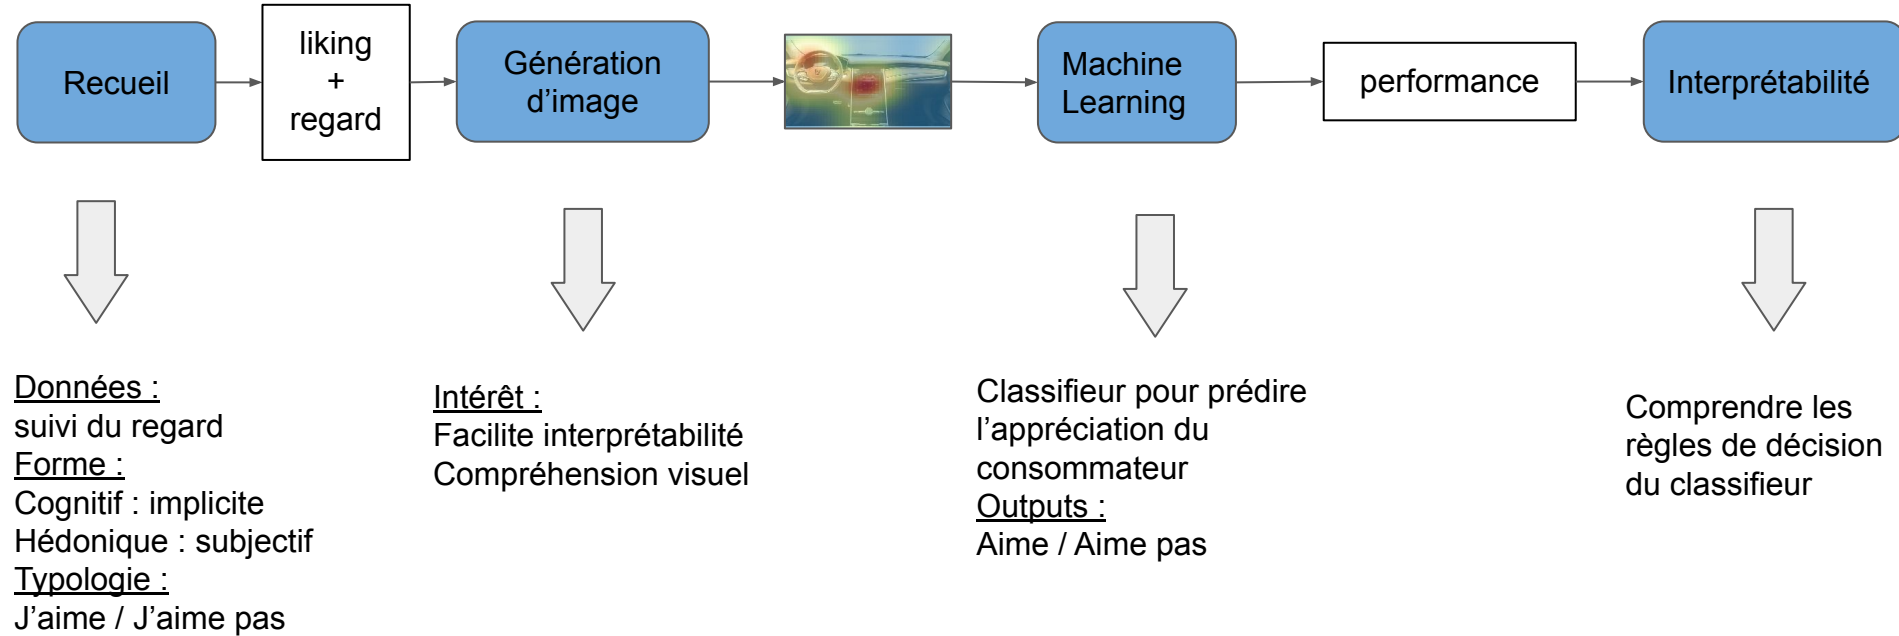
On est déçus de ne pas pouvoir monter notre start-up dès demain

Merci à Mr.Lê et à Muriel ainsi qu'à tous ceux qui sont venus se cramer la rétine !

Merci pour votre attention !



4 axes d'attaques pour concentrer les réflexions.



1. Recueil de données
 - a. L'outil
 - b. Le protocole
 - c. La donnée
2. Génération des inputs ML
 - a. Développement d'une méthode de correction
 - b. Application à nos données
 - c. Autres idées de correction
3. ML
 - a. le choix du modèle + forme des datas
 - b. résultats
4. Interprétabilité
 - a. interprétabilité et choix (parler des fakes datas?)
5. Comment améliorer le projet ?

1) Mise en situation - Prise en main et structure

Un sujet ouvert :

- mots clefs :


- "eye-tracking" → approche cognitive, données implicites, résultats subjectifs
- "webcam" + "domicile" → Pas d'outils nouveaux
- "interprétabilité" + "machine learning" → Compétences M2

Créer de l'assurance?

- Problématique d'étude : L'interprétabilité en machine Learning permet-elle de comprendre des données subjectives et implicites tel que l'hédonisme dans le regard ?
- Objectif de la mise en œuvre
 - Reproductibilité
 - Générer des données de eye-tracking qui traduisent l'hédonisme
 - Interpréter des résultats de ML présentés comme images (LIME)



1) Mise en situation - Première semaine : fondation

- Les outils:
 - Des attentes logiciel :
 - Webcam, forme données, gratuité
 - Nos moyens :
 - Des webcams intégrés et des caméras
 - Nos ordinateurs
 - R ou python
 - Ce qu'on aimerait :
 - Une caméra Tobii
- Envisager l'interprétation
 - Le regard traduit l'hédonisme ?
 - Chemin d'analyse du stimuli ? L'ordre ? La durée ?
 - Traduire ces idées en visualisation pour un algorithme




2) Recueil des données - le nudge

- Le nudge :
 - Incitation douce pour modifier le comportement
- Données implicites :
 - Conserver la dimension subjective
 - Le regard ne veut pas dire aimer
- Plusieurs tentatives :
 - Une vidéo « explicative »
 - Appréciation dichotomique
 - Expression faciale
 - Phrasé axé marketing et appréciation




Merci !



2 - Recueil de donnée - questionnaire


- recueil de co-variables pouvant ajouter de l'information aux heatmaps obtenues
- Des variables sur l'importance des éléments d'un véhicule, propre aux produits mais évalués par un conso et des variables sur le consommateur et son rapport à la conduite
- retour conso sur le protocole, implicite et cognitif ont besoin d'une forme de validation
- typologie de conso et relier ça aux résultats et retour senso
- On a que des étudiants donc le panel manque peut être de variétés mais ils ont un rapport différent au fait de consommer : autant dans l'appréciation que dans l'usage que dans la multiplicité de leur véhicule (usage = ville ou campagne par ex)



2 - Recueil de donnée - limites


Critique protocole :


- stimuli papier \neq stimuli sur écran numérique.
- changement d'avis pendant visualisation longue \Rightarrow étiquetage imparfait de nos stimuli
 - limite des perspectives d'études
- début du regard toujours au même endroit (fin de la calibration)
- tâche aliénante



Autres inputs possibles

- heatmaps temporelle → donner de la valence au temps.
 - Heatmaps sur AOI.
 - Normalisation par ind / cockpit pour donner plus d'importance au temps.
-
- heatmap signée → intégrer un commentaire conso sur chacune des heatmaps et demander à l'utilisateur les caractéristiques des zones d'intensité sur le liking
 - ajouter des co-variables (questionnaire) en plus d'une image dans un modèle de ML.





2.3 Autre pistes de correction

Ce que l'on a fait : classification par ACP + HCPC des points


Ce que l'on pourrait faire :

- gaussienne pour apporter plus d'importance aux centres de chaque classes
- grilles de correction

Analyser la qualité de nos données :

- utiliser les 25 carrés pour evaluer la fiabilité des corrections appliqués.
- mise en place d'un score pour sélectionner les “belles” données.

→ exploiter uniquement les enregistrement bien calibrés



3.1 Les données en entrée

On a donc a un jeu de données avec :

- la variable réponse d'appréciation Y qualitative à 2 modalités : 16x34 observations
- les heatmaps générées pour les entrées de notre modèle : 16x34 tableau 3D

Vérifiez certaines hypothèses :

Effet produit




Effet juge



FigureX : Effet des différents stimulus sur l'appréciation

3.3 Données simulées

Label 1



Label 2

